

МИНИСТЕРСТВО ЦИФРОВОГО РАЗВИТИЯ, СВЯЗИ И МАССОВЫХ
КОММУНИКАЦИЙ
РОССИЙСКОЙ ФЕДЕРАЦИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Сибирский государственный университет телекоммуникаций и
информатики»

Кафедра телекоммуникационных систем и вычислительных средств
(ТС и ВС)

Отчет
по дисциплине
«Системы искусственного интеллекта»

по теме:
ЛАБОРАТОРНАЯ РАБОТА 1. ПЕРВИЧНЫЙ АНАЛИЗ ДАННЫХ

Студент:
Группа ИА331

P.K. Рубцов

Предподаватель:
.

K.I. Брагин

Новосибирск 2026 г.

СОДЕРЖАНИЕ

ЛАБОРАТОРНАЯ РАБОТА 1. ПЕРВИЧНЫЙ АНАЛИЗ ДАННЫХ	3
0.1 Цель работы	3
0.2 Описание набора данных	3
0.2.1 Назначение и возможные задачи	3
0.2.2 Описание признаков	4
0.3 Форма и статистика набора данных	4
0.3.1 Статистические показатели	4
0.3.2 Топ-5 самых популярных имён	5
0.3.3 Предположения на основе анализа	5
0.4 Исходный код программы	5
0.5 Консольный вывод	7
0.6 Графические представления	8
0.7 Ответы на контрольные вопросы	10
0.8 Выводы	11

ЛАБОРАТОРНАЯ РАБОТА 1. ПЕРВИЧНЫЙ АНАЛИЗ ДАННЫХ

0.1 Цель работы

Изучение программных средств для организации рабочего места специалиста по анализу данных и машинному обучению; выполнение первичного анализа набора данных об именах; получение обобщённых характеристик и визуализация структуры данных.

0.2 Описание набора данных

В качестве обучающего набора данных использован датасет name_gender_dataset.csv, содержащий 147 269 записей о популярных именах с указанием пола, количества носителей и вероятности встречаемости.

0.2.1 Назначение и возможные задачи

Набор предназначен для обучения методам анализа данных, в частности:

- анализа распределения имён по полу;
- изучения статистики популярности имён;
- визуализации демографических данных;
- выявления закономерностей в частоте использования имён.

0.2.2 Описание признаков

Таблица 1 — Характеристики признаков датасета

№	Признак	Описание и тип
1	name	Имя (строковый, до 20 символов)
2	gender	Пол: М (мужской) или F (женский) (категориальный)
3	count	Количество носителей имени (целочисленный)
4	probability	Вероятность встречаемости имени (вещественный)

0.3 Форма и статистика набора данных

- Количество объектов: 147 269
- Количество признаков: 4 (3 входных + 1 целевой)
- Распределение по полу: мужские имена — 57 520 (39.0%), женские имена — 89 749 (61.0%)

0.3.1 Статистические показатели

Таблица 2 — Основные статистики по числовым признакам

Признак	Среднее	Мин.	Макс.
count	≈1 200	1	5 304 407
probability	≈0.003	<0.0001	0.0145

0.3.2 Топ-5 самых популярных имён

Таблица 3 — Наиболее распространённые имена

№	Имя	Пол	Количество
1	James	M	5 304 407
2	John	M	5 260 831
3	Robert	M	4 970 386
4	Michael	M	4 579 950
5	William	M	4 226 608

0.3.3 Предположения на основе анализа

- Мужские имена в топ-15 доминируют по количеству носителей.
- В датасете представлено больше женских имён (89 749 против 57 520), но их общая популярность ниже.

0.4 Исходный код программы

Для выполнения первичного анализа и визуализации данных был написан следующий скрипт на языке Python:

```
import numpy as np
from matplotlib import pyplot as plt

dt = np.dtype([
    ('name', 'U20'),
    ('gender', 'U1'),
    ('count', 'i4'),
    ('probability', 'f8')
])

data = np.genfromtxt("name_gender_dataset.csv", delimiter=",",
                     dtype=dt, skip_header=1, encoding='utf-8')

print(f'Тип данных: {type(data)}')
print(f'Тип записи: {type(data[0])}')
print(f'Тип имени: {type(data[0][0])}'
```

```

print(f'Формат данных: {data.shape}')
print(f'\nПервые 5 записей:')
print(data[:5])

male_mask = data['gender'] == 'M'
female_mask = data['gender'] == 'F'

male_data = data[male_mask]
female_data = data[female_mask]

print(f'\nМужских имен: {len(male_data)}')
print(f'Женских имен: {len(female_data)}')

sorted_by_count = np.sort(data, order='count')[::-1]

# График 1: Топ-15 имен
plt.figure(1)
top_15 = sorted_by_count[:15]
colors = ['#1f77b4' if g == 'M' else '#ff7f0e' for g in top_15['gender']]
plt.barh(range(15), top_15['count'], color=colors)
plt.yticks(range(15), top_15['name'])
plt.xlabel('Количество носителей')
plt.title('Топ-15 самых популярных имен')
plt.gca().invert_yaxis()
plt.tight_layout()

# График 2: Распределение полу
plt.figure(2)
male_total = male_data['count'].sum()
female_total = female_data['count'].sum()
plt.pie([male_total, female_total],
        labels=[f'Мужские ({male_total:,})', f'Женские ({female_total:,})'],
        colors=['#1f77b4', '#ff7f0e'])
plt.title('Доля имен по полу общее (количество носителей)')
plt.axis('equal')

# График 3: Зависимость Probability от Count
plt.figure(3)
plt.scatter(male_data['count'], male_data['probability'],
            c='#1f77b4', label='Мужские')

```

```

plt.scatter(female_data['count'], female_data['probability'],
            c='#ff7f0e', label='Женские')
plt.xlabel('Количествоносителей (Count)')
plt.ylabel('Вероятность (Probability)')
plt.title('Зависимость Probability от Count')
plt.legend()
plt.grid()

# График 4: Топ-10 полу
plt.figure(4)
male_sorted = np.sort(male_data, order='count')[::-1][:10]
plt.subplot(1, 2, 1)
plt.barh(range(10), male_sorted['count'], color='#1f77b4')
plt.yticks(range(10), male_sorted['name'])
plt.xlabel('Количество')
plt.title('Топ-10 мужских имён')
plt.gca().invert_yaxis()
plt.grid()

female_sorted = np.sort(female_data, order='count')[::-1][:10]
plt.subplot(1, 2, 2)
plt.barh(range(10), female_sorted['count'], color='#ff7f0e')
plt.yticks(range(10), female_sorted['name'])
plt.xlabel('Количество')
plt.title('Топ-10 женских имён')
plt.gca().invert_yaxis()
plt.grid()

plt.tight_layout()
plt.show()

```

Листинг 1 — Исходный код программы

0.5 Консольный вывод

При выполнении скрипта в терминале были получены следующие данные:

Тип данных
: <class 'numpy.ndarray'> Тип записи
: <class 'numpy.void'> Тип имени
: <class 'numpy.str_'> Форма данных

```
: (147269,) Первые
```

```
5 записей:
```

```
[('James', 'М', 5304407, 0.01451679), ('John', 'М', 5260831, 0.01439753), ('Robert', 'М', 4970386, 0.01360266), ('Michael', 'М', 4579950, 0.01253414), ('William', 'М', 4226608, 0.01156713)] Мужскихимён
```

```
: 57520 Женскихимён
```

```
: 89749
```

Листинг 2 — Результаты в терминале

А также графики (рис. 1–4).

0.6 Графические представления




Рисунок 1 — Топ-15 самых популярных имён. Видно доминирование мужских имён (синие) в верхней части рейтинга. Женские имена (оранжевые) появляются реже, но также входят в топ (Mary, Elizabeth).




Рисунок 2 — Распределение общего количества носителей по полу. Несмотря на то, что женских имён в датасете больше (89 749 против 57 520), общее количество носителей мужских имён превышает количество носителей женских имён.




Рисунок 3 — Зависимость Probability от Count. Мужские имена (синие) занимают верхнюю часть графика, что подтверждает их большую популярность.




Рисунок 4 — Топ-10 мужских и женских имён. James, John и Robert лидируют среди мужских имён с показателями свыше 4-5 миллионов носителей. Среди женских имён Mary значительно опережает остальные с показателем около 4 миллионов.

0.7 Ответы на контрольные вопросы

1. **Инструментальные средства для Data Science:** Jupyter Notebook, Google Colab, VS Code с расширениями, PyCharm, Anaconda, Git, терминал Linux/WSL.
2. **Библиотеки Python для ML:**
 - NumPy — работа с многомерными массивами и математическими операциями.
 - Pandas — загрузка, обработка и анализ табличных данных.
 - Matplotlib/Seaborn — визуализация данных.
 - Scikit-learn — реализация алгоритмов ML (классификация, регрессия, кластеризация).
 - SciPy — научные вычисления и статистика.
3. **Почему Python популярен в ML?** Простой синтаксис, огромное сообщество, богатая экосистема библиотек, поддержка научных вычислений, удобство для прототипирования и обучения.

0.8 Выводы

Проведённый первичный анализ показал, что датасет name_gender_dataset.csv обладает следующими свойствами:

- большой объём данных (147 269 записей),
- неравномерное распределение по полу (больше женских имён, но мужские более популярны),
- явное доминирование нескольких имён (James, John, Robert, Mary),
- распределение подчиняется степенному закону (немного очень популярных имён, много редких).

Датасет подходит для задач:

- анализа популярности имён,
- демографических исследований,
- прогнозирования трендов именования,
- классификации имён по полу.

Студент группы ИА331

Рубцов Р.К.