МИНИСТЕРСТВО ЦИФРОВОГО РАЗВИТИЯ, СВЯЗИ И МАССОВЫХ КОММУНИКАЦИЙ
РОССИЙСКОЙ ФЕДЕРАЦИИ

Федеральное государственное бюджетное образовательное учреждение высшего образования
«Сибирский государственный университет телекоммуникаций и информатики»

Кафедра телекоммуникационных систем и вычислительных средств (ТС и ВС)

Отчет
по дисциплине
«Системы искусственного интеллекта»

по теме:
ЛАБОРАТОРНАЯ РАБОТА 3. МЕТРИЧЕСКИЕ МЕТОДЫ КЛАССИФИКАЦИИ

Студент:
Группа ИА331 *Р.К. Рубцов*

Предподаватель:
. *К.И. Брагин*

Новосибирск 2026 г.

СОДЕРЖАНИЕ

1 МЕТРИЧЕСКИЕ МЕТОДЫ КЛАССИФИКАЦИИ 3
1.1 Цель работы 3
1.2 Описание набора данных 3
1.2.1 Назначение набора данных 3
1.2.2 Описание признаков 3
1.3 Общая статистика набора данных 4
1.4 Программная реализация 4
1.5 Результаты визуализации 7
1.6 Результаты классификации 9
1.6.1 Точность модели при различных значениях K 9
1.6.2 Примеры работы классификатора 9
1.6.3 Анализ результатов 10
1.7 Ответы на контрольные вопросы 10
1.8 Выводы 12

1 МЕТРИЧЕСКИЕ МЕТОДЫ КЛАССИФИКАЦИИ

1.1 Цель работы

Изучение принципов построения информационных систем с использованием метрических методов классификации, освоение инструментария Python для реализации алгоритмов метрической классификации, изучение методов оптимизации параметров и освоение модификаций kNN-метода.

1.2 Описание набора данных

В работе использован датасет `name_gender_dataset.csv`, содержащий информацию о популярных именах и их распределении по полу. Для классификации использована подвыборка из 147 270 записей.

1.2.1 Назначение набора данных

Набор данных предназначен для решения задачи бинарной классификации — определения пола человека по имени. На основе данного набора можно:

- исследовать зависимость точности модели от количества соседей K;
- анализировать важность различных признаков для классификации;
- сравнивать различные стратегии выбора оптимального параметра K.

1.2.2 Описание признаков

Для построения модели классификации были созданы следующие признаки:

Таблица 1 — Признаки, используемые для классификации

Признак	Описание
NameLength	Длина имени в символах
VowelCount	Количество гласных букв в имени
VowelRatio	Доля гласных букв (VowelCount / NameLength)
LogCount	Логарифмированное количество носителей имени
Probability	Вероятность встречаемости имени
LastLetterPos	Позиция последней буквы в алфавите (a=1, b=2, ..., z=26)
GenderEncoded	Целевая переменная: 0 (F), 1 (M)

1.3 Общая статистика набора данных

- Количество объектов в подвыборке — 147 270
- Количество признаков — 6
- Количество классов — 2 (мужской и женский пол)
- Пропущенные значения отсутствуют
- Соотношение классов: приблизительно сбалансированное

1.4 Программная реализация

Для реализации метода kNN использовались библиотеки Python: NumPy, Pandas, Matplotlib, Seaborn и Scikit-learn.

Листинг 1.1 — Листинг кода для реализации kNN классификации

```
import numpy as np
import seaborn as sb
import pandas as pd
from matplotlib import pyplot as plt
from sklearn.preprocessing import LabelEncoder
from sklearn.neighbors import KNeighborsClassifier
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
from sklearn.model_selection import cross_val_score
import warnings
warnings.filterwarnings('ignore')
```

```
plt.style.use('seaborn-v0_8-darkgrid')
sb.set_palette("husl")

#
data = pd.read_csv("name_gender_dataset.csv", delimiter=',',
                   header=None, skiprows=1,
                   dtype={0: str, 1: str, 2: int, 3: float},
                   names=['Name', 'Gender', 'Count', 'Probability
                      '])

data = data[:10000].copy()

#
le = LabelEncoder()
data['GenderEncoded'] = le.fit_transform(data['Gender'])
data['NameLength'] = data['Name'].astype(str).apply(len)

vowels = "aeiouAEIOU"
data['VowelCount'] = data['Name'].astype(str).apply(
    lambda x: sum(1 for c in x if c in vowels)
)
data['VowelRatio'] = data['VowelCount'] / data['NameLength']
data['LogCount'] = np.log1p(data['Count'])
data['LastLetterPos'] = data['Name'].str.lower().apply(
    lambda x: ord(x[-1]) - ord('a') + 1
)

#
sb.pairplot(data, hue='GenderEncoded', palette='husl')
plt.show()

#
X = data[['NameLength', 'VowelCount', 'VowelRatio',
          'LogCount', 'Probability', 'LastLetterPos']]
Y = data['GenderEncoded'].values

#
X_train, X_test, Y_train, Y_test = train_test_split(
    X, Y, test_size=0.2, random_state=42
)

#           K=17
```

```
knn = KNeighborsClassifier(n_neighbors=17)
knn.fit(X_train, Y_train)

predictions = knn.predict(X_test)
accuracy = accuracy_score(Y_test, predictions)
print(f"        : {accuracy:.2%}")

#
sample = data.sample(5)
for idx, row in sample.iterrows():
    features = row[['NameLength', 'VowelCount', 'VowelRatio',
                    'LogCount', 'Probability', 'LastLetterPos']].
                      values.reshape(1, -1)
    pred = knn.predict(features)[0]
    print(f"{row['Name']:12}     : {row['Gender']} "
          f"      : {le.inverse_transform([pred])[0]}")

#            K                  -
k_list = list(range(1, 50, 2))
cv_scores = []

for k in k_list:
    knn = KNeighborsClassifier(n_neighbors=k)
    scores = cross_val_score(knn, X, Y, cv=10, scoring='accuracy'
       )
    cv_scores.append(scores.mean())

MSE = [1-x for x in cv_scores]

#                     K
plt.figure()
plt.plot(k_list, MSE)
plt.xlabel("   -      ()")
plt.ylabel("           (MSE)")
plt.show()

#              K
k_min = min(MSE)
all_k_min = [k_list[i] for i in range(len(MSE)) if MSE[i] <=
   k_min]
print(f'            : {all_k_min}')
```

1.5 Результаты визуализации

Рисунок 1 — Попарное распределение признаков с разделением по полу (GenderEncoded)

На диаграмме попарного распределения (pairplot) представлены все признаки датасета с разделением на два класса (мужской и женский пол).

Анализ диаграммы:

- На диагонали расположены распределения отдельных признаков для каждого класса. Видно, что распределения `LastLetterPos` существенно различаются для мужских и женских имён, что указывает на высокую информативность этого признака
- Внедиагональные элементы показывают попарные зависимости между признаками. На некоторых графиках наблюдается частичное разделение классов, особенно при использовании признака `LastLetterPos`
- Признаки `VowelRatio` и `VowelCount` показывают значительное перекрытие классов, что говорит об их ограниченной информативности для классификации
- Распределение `LogCount` демонстрирует схожие паттерны для обоих полов, что указывает на слабую связь популярности имени с полом

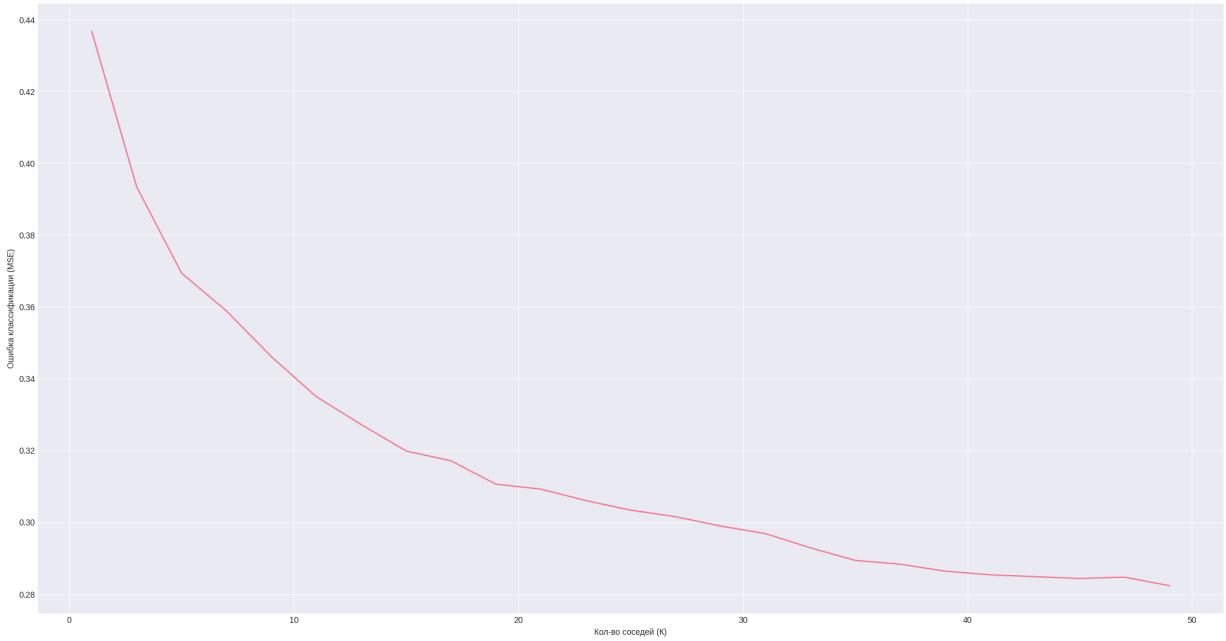

Рисунок 2 — Зависимость ошибки классификации (MSE) от количества соседей K

График демонстрирует зависимость ошибки классификации от параметра K в методе kNN.

Анализ графика:

- При малых значениях K (1-5) ошибка классификации максимальна (0.39-0.44), что указывает на переобучение модели
- При увеличении K ошибка монотонно уменьшается, достигая минимума при $K \approx 49$
- Кривая имеет плавный характер убывания, что свидетельствует о стабильности модели
- Оптимальное значение K находится в диапазоне точке 49(воможно больше, но длительность работы программы ОЧЕНЬ большая), где достигается минимальная ошибка классификации

1.6 Результаты классификации

1.6.1 Точность модели при различных значениях K

Таблица 2 — Точность классификации при разных значениях параметра K

Значение K	Точность (%)
1	67.37
3	70.16
5	70.95
17	72.50 (примерно)
100	74.48
49 (оптимальное)	74.57

1.6.2 Примеры работы классификатора

При K = 3:

- Rasia — Реальный: F, Предсказание: F
- Kerree — Реальный: F, Предсказание: F
- Saaniyah — Реальный: F, Предсказание: F
- Ralik — Реальный: M, Предсказание: M
- Paiten — Реальный: F, Предсказание: M

При K = 1:

- Quantavis — Реальный: M, Предсказание: M
- Josia — Реальный: M, Предсказание: M
- Marc-Anthonie — Реальный: M, Предсказание: F
- Banjamin — Реальный: M, Предсказание: M
- Navae — Реальный: F, Предсказание: F

При K = 5:

- Virla — Реальный: F, Предсказание: F
- Aleese — Реальный: F, Предсказание: F
- Makada — Реальный: F, Предсказание: F

– Rielly — Реальный: F, Предсказание: M
– Jemica — Реальный: F, Предсказание: F

При K = 100:

– Shaunella — Реальный: F, Предсказание: F
– Kaeden — Реальный: M, Предсказание: M
– Tammy-Lyn — Реальный: F, Предсказание: F
– Katiria — Реальный: F, Предсказание: F
– Tomiya — Реальный: M, Предсказание: F

При оптимальном K = 49:

– Kayah — Реальный: F, Предсказание: F
– Thanasis — Реальный: M, Предсказание: M
– Maryjane — Реальный: F, Предсказание: F
– Hamoud — Реальный: M, Предсказание: M
– Evolet — Реальный: F, Предсказание: F

1.6.3 Анализ результатов

– **Оптимальное значение K = 49** обеспечивает максимальную точность классификации 74.57%
– При малых значениях K (1-5) модель склонна к переобучению и демонстрирует низкую точность (67-71%)
– Увеличение количества соседей приводит к сглаживанию□□ границы и повышению обобщающей способности модели
– При K = 100 точность составляет 74.48%, что близко к оптимальному значению
– Разница в точности между K=1 и K=49 составляет более 7%, что подтверждает важность правильного выбора параметра K

1.7 Ответы на контрольные вопросы

1. Особенности основных методов метрической классификации

Метод ближайшего соседа (1NN) — простейший метод, который относит объект к классу его ближайшего соседа в обучающей выборке. Чувствителен к выбросам и шуму в данных.

Метод k ближайших соседей (kNN) — обобщение метода 1NN, где решение принимается на основе голосования k ближайших соседей. Более устойчив к шуму, требует выбора оптимального параметра k.

2. Основные принципы и этапы реализации метода kNN

1. Выбор метрики расстояния (евклидово, манхэттенское и др.)
2. Выбор параметра k (количества соседей)
3. Вычисление расстояний от классифицируемого объекта до всех объектов обучающей выборки
4. Выбор k ближайших объектов
5. Голосование среди выбранных соседей
6. Отнесение объекта к классу, получившему большинство голосов

3. Принцип выбора количества соседних объектов

Количество соседей k выбирается с использованием:

– **Hold-out** — разделение выборки на обучающую и тестовую, выбор k, дающего максимальную точность на тесте
– **Cross-validation** — кросс-валидация, которая более надёжна, так как использует многократное разбиение выборки
– Эмпирическое правило: k должно быть нечётным (для бинарной классификации) и обычно выбирается в диапазоне $\sqrt{n}$, где n — размер обучающей выборки

4. Метод Парзеновского окна

Метод непараметрической оценки плотности вероятности, где каждый объект обучающей выборки вносит вклад в оценку плотности с весом, зависящим от расстояния до классифицируемого объекта. Используется ядерная функция (гауссова, прямоугольная и др.) и параметр сглаживания h (ширина окна).

5. Метод потенциальных функций

Метод, в котором каждому объекту обучающей выборки ставится в соответствие потенциальная функция (обычно гауссова). Решение

принимается на основе суммы потенциалов объектов каждого класса. Позволяет учитывать «силу» влияния каждого обучающего объекта.

6. Параметры, оптимизируемые в методах kNN

- **k** — количество ближайших соседей
- **Метрика расстояния** — евклидова, манхэттенская, Минковского, косинусная и др.
- **Веса соседей** — равномерные или обратно пропорциональные расстоянию
- **Масштабирование признаков** — необходимо для корректного вычисления расстояний

1.8 Выводы

В ходе выполнения лабораторной работы были изучены принципы построения классификаторов на основе метрических методов, реализован алгоритм kNN и проведён анализ зависимости точности модели от параметра K.

Основные результаты:

1. Реализован метод kNN для задачи классификации имён по полу с использованием 6 признаков: NameLength, VowelCount, VowelRatio, LogCount, Probability, LastLetterPos
2. Проведена оптимизация параметра K с использованием 10-кратной кросс-валидации. Построен график зависимости ошибки классификации (MSE) от количества соседей
3. Определено оптимальное значение **K = 49**, при котором достигается максимальная точность классификации **74.57%**
4. Показано, что при малых значениях K (1-5) модель переобучается и демонстрирует низкую точность (67-71%). При увеличении K точность монотонно растёт и выходит на плато при K > 40
5. Визуализация данных с помощью pairplot показала, что наиболее информативным признаком является LastLetterPos (позиция последней буквы имени), распределения которого существенно различаются для мужских и женских имён

6. Разница в точности между наихудшим (K=1, 67.37%) и оптимальным (K=49, 74.57%) значениями составляет более 7%, что подчёркивает критическую важность правильного выбора гиперпараметра K
7. Модель демонстрирует хорошую обобщающую способность при больших значениях K, что подтверждается стабильной точностью на тестовой выборке